

# GRU4REC

序列化推薦系統

6/21

柏威

# Source

- Session-based recommendations with recurrent neural networks. (ICLR 2016)

# GRU4REC

**Session-based  
Neural network**

**Recommendation**

# Why Session based

Session 是伺服器端用來有時序關係的記錄、識別使用者的一種機制。  
典型的場景比如購物車，服務端為特定的物件建立了特定的 Session，用於標識這個物件，並且跟蹤使用者的瀏覽點選行為。

# 傳統推薦演算法


- Content-based
- Collaborative Filtering

每個item互相獨立，沒有辦法考量時序性

**如何考量時序性？**

# 傳統解法 (1)

- Item to item recommendation: 用item間的相似性預測下一個item

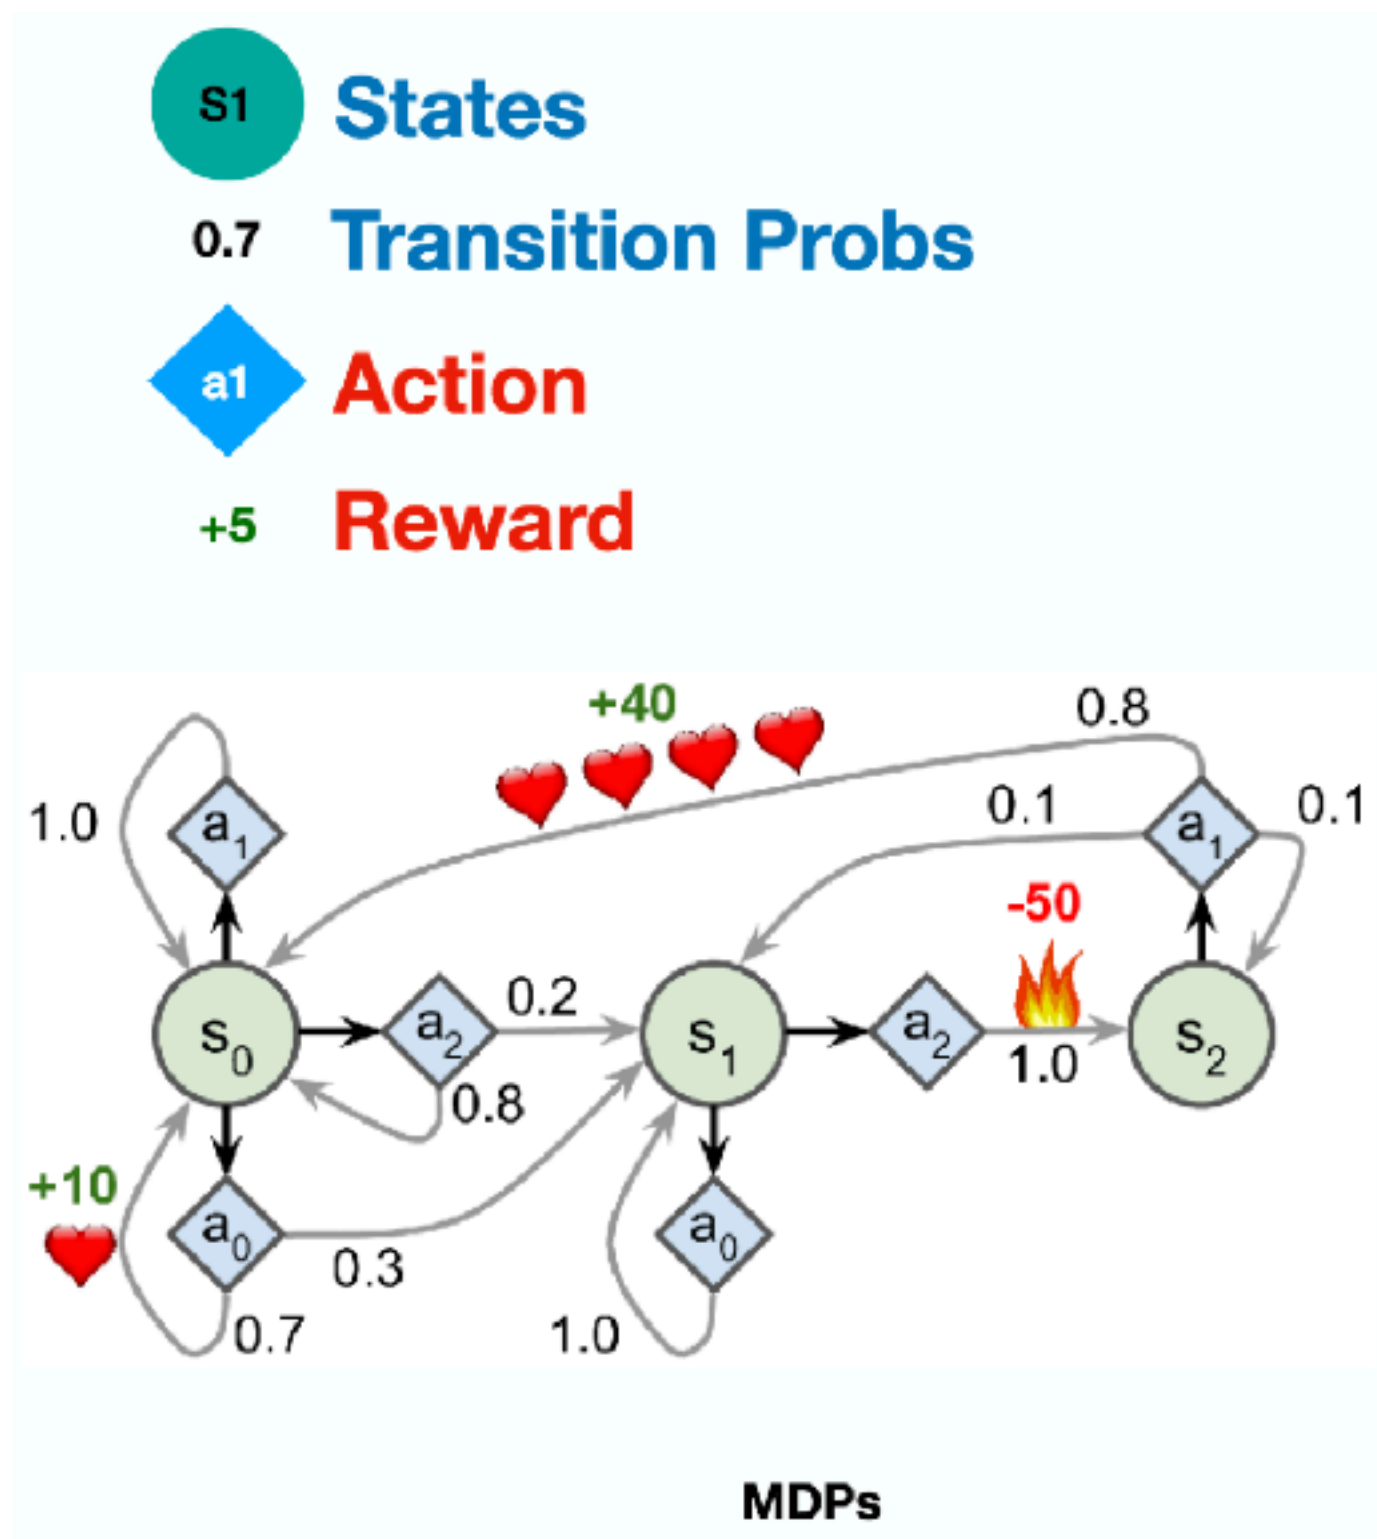


```
For each item in product catalog,  $I_1$ 
  For each customer  $C$  who purchased  $I_1$ 
    For each item  $I_2$  purchased by
      customer  $C$ 
      Record that a customer purchased  $I_1$ 
        and  $I_2$ 
  For each item  $I_2$ 
    Compute the similarity between  $I_1$  and  $I_2$ 
```

缺點：只考慮最後一個click的item相似性

# 傳統解法 (2)

- Markov Decision Processes (MDPs)：馬可夫狀態轉移的四個狀態 (S:狀態, A:動作, P:轉移機率, R:獎勵函數) 用狀態轉移機率計算點擊下一個item的機率。



- 轉移機率(*transition probability*)：  
在目前狀態 $S_t$ 為 $s$ ，目前執行動作 $A_t$ 為 $a$ 的情況下，下一期狀態 $S_{t+1}$ 為 $s'$ 的機率。

$$P_a(s, s') = \mathbb{P}(S_{t+1} = s' | S_t = s, A_t = a)$$

- 報酬函數 (*expected reward*)：  
，在目前狀態 $S_t$ 為 $s$ ，目前執行動作 $A_t$ 為 $a$ ，下一期狀態 $S_{t+1}$ 為 $s'$ 的情況下，該動作可以得到的期望報酬。 $(S_{t+1}, R_a(s))$  存在聯合分配(*joint distribution*)。

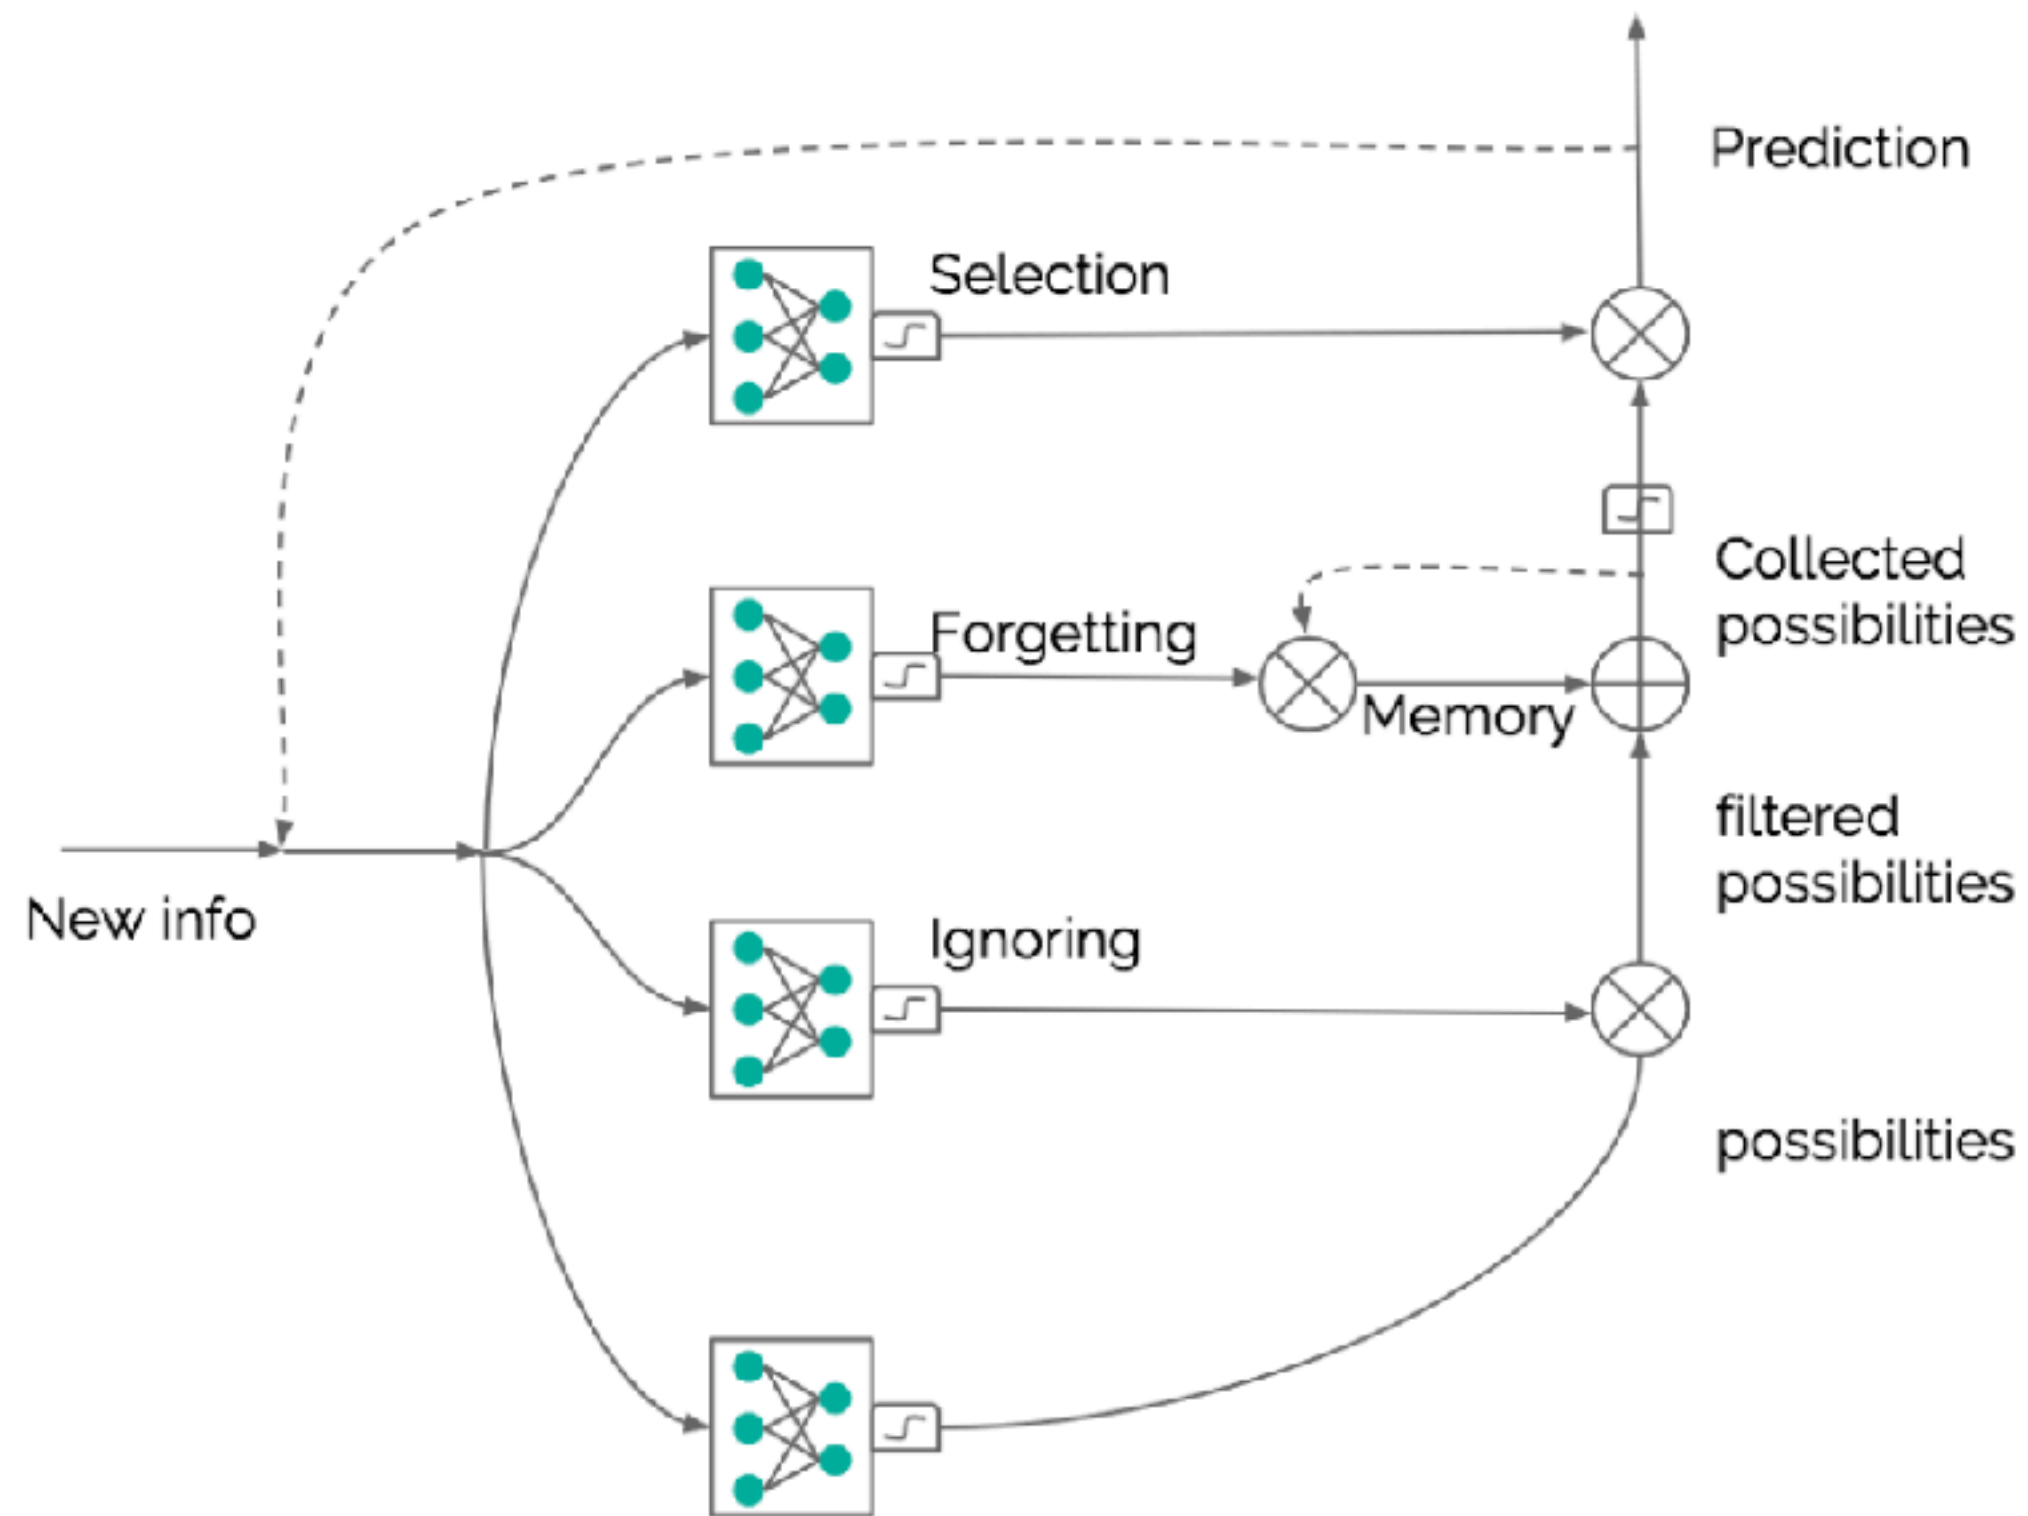
$$R_a(s) = R_{t+1} | S_t = s, a_t = a$$

缺點：狀態數量大，隨問題維度指數增加



# Deep Neural Network

# 先複習一下LSTM



$\otimes$  Element by element multiplication


$\oplus$  Element by element addition

$\sigma$  Squashing function



三個門：輸入門、輸出門、遺忘門

# LSTM

- $C$  變化緩慢（記憶功能的訊息傳遞）
- $h$  變化較快



# LSTM



$$z = \tanh\left(W \begin{bmatrix} x^t \\ h^{t-1} \end{bmatrix}\right)$$

$$z^i = \sigma\left(W^i \begin{bmatrix} x^t \\ h^{t-1} \end{bmatrix}\right)$$

Input gate

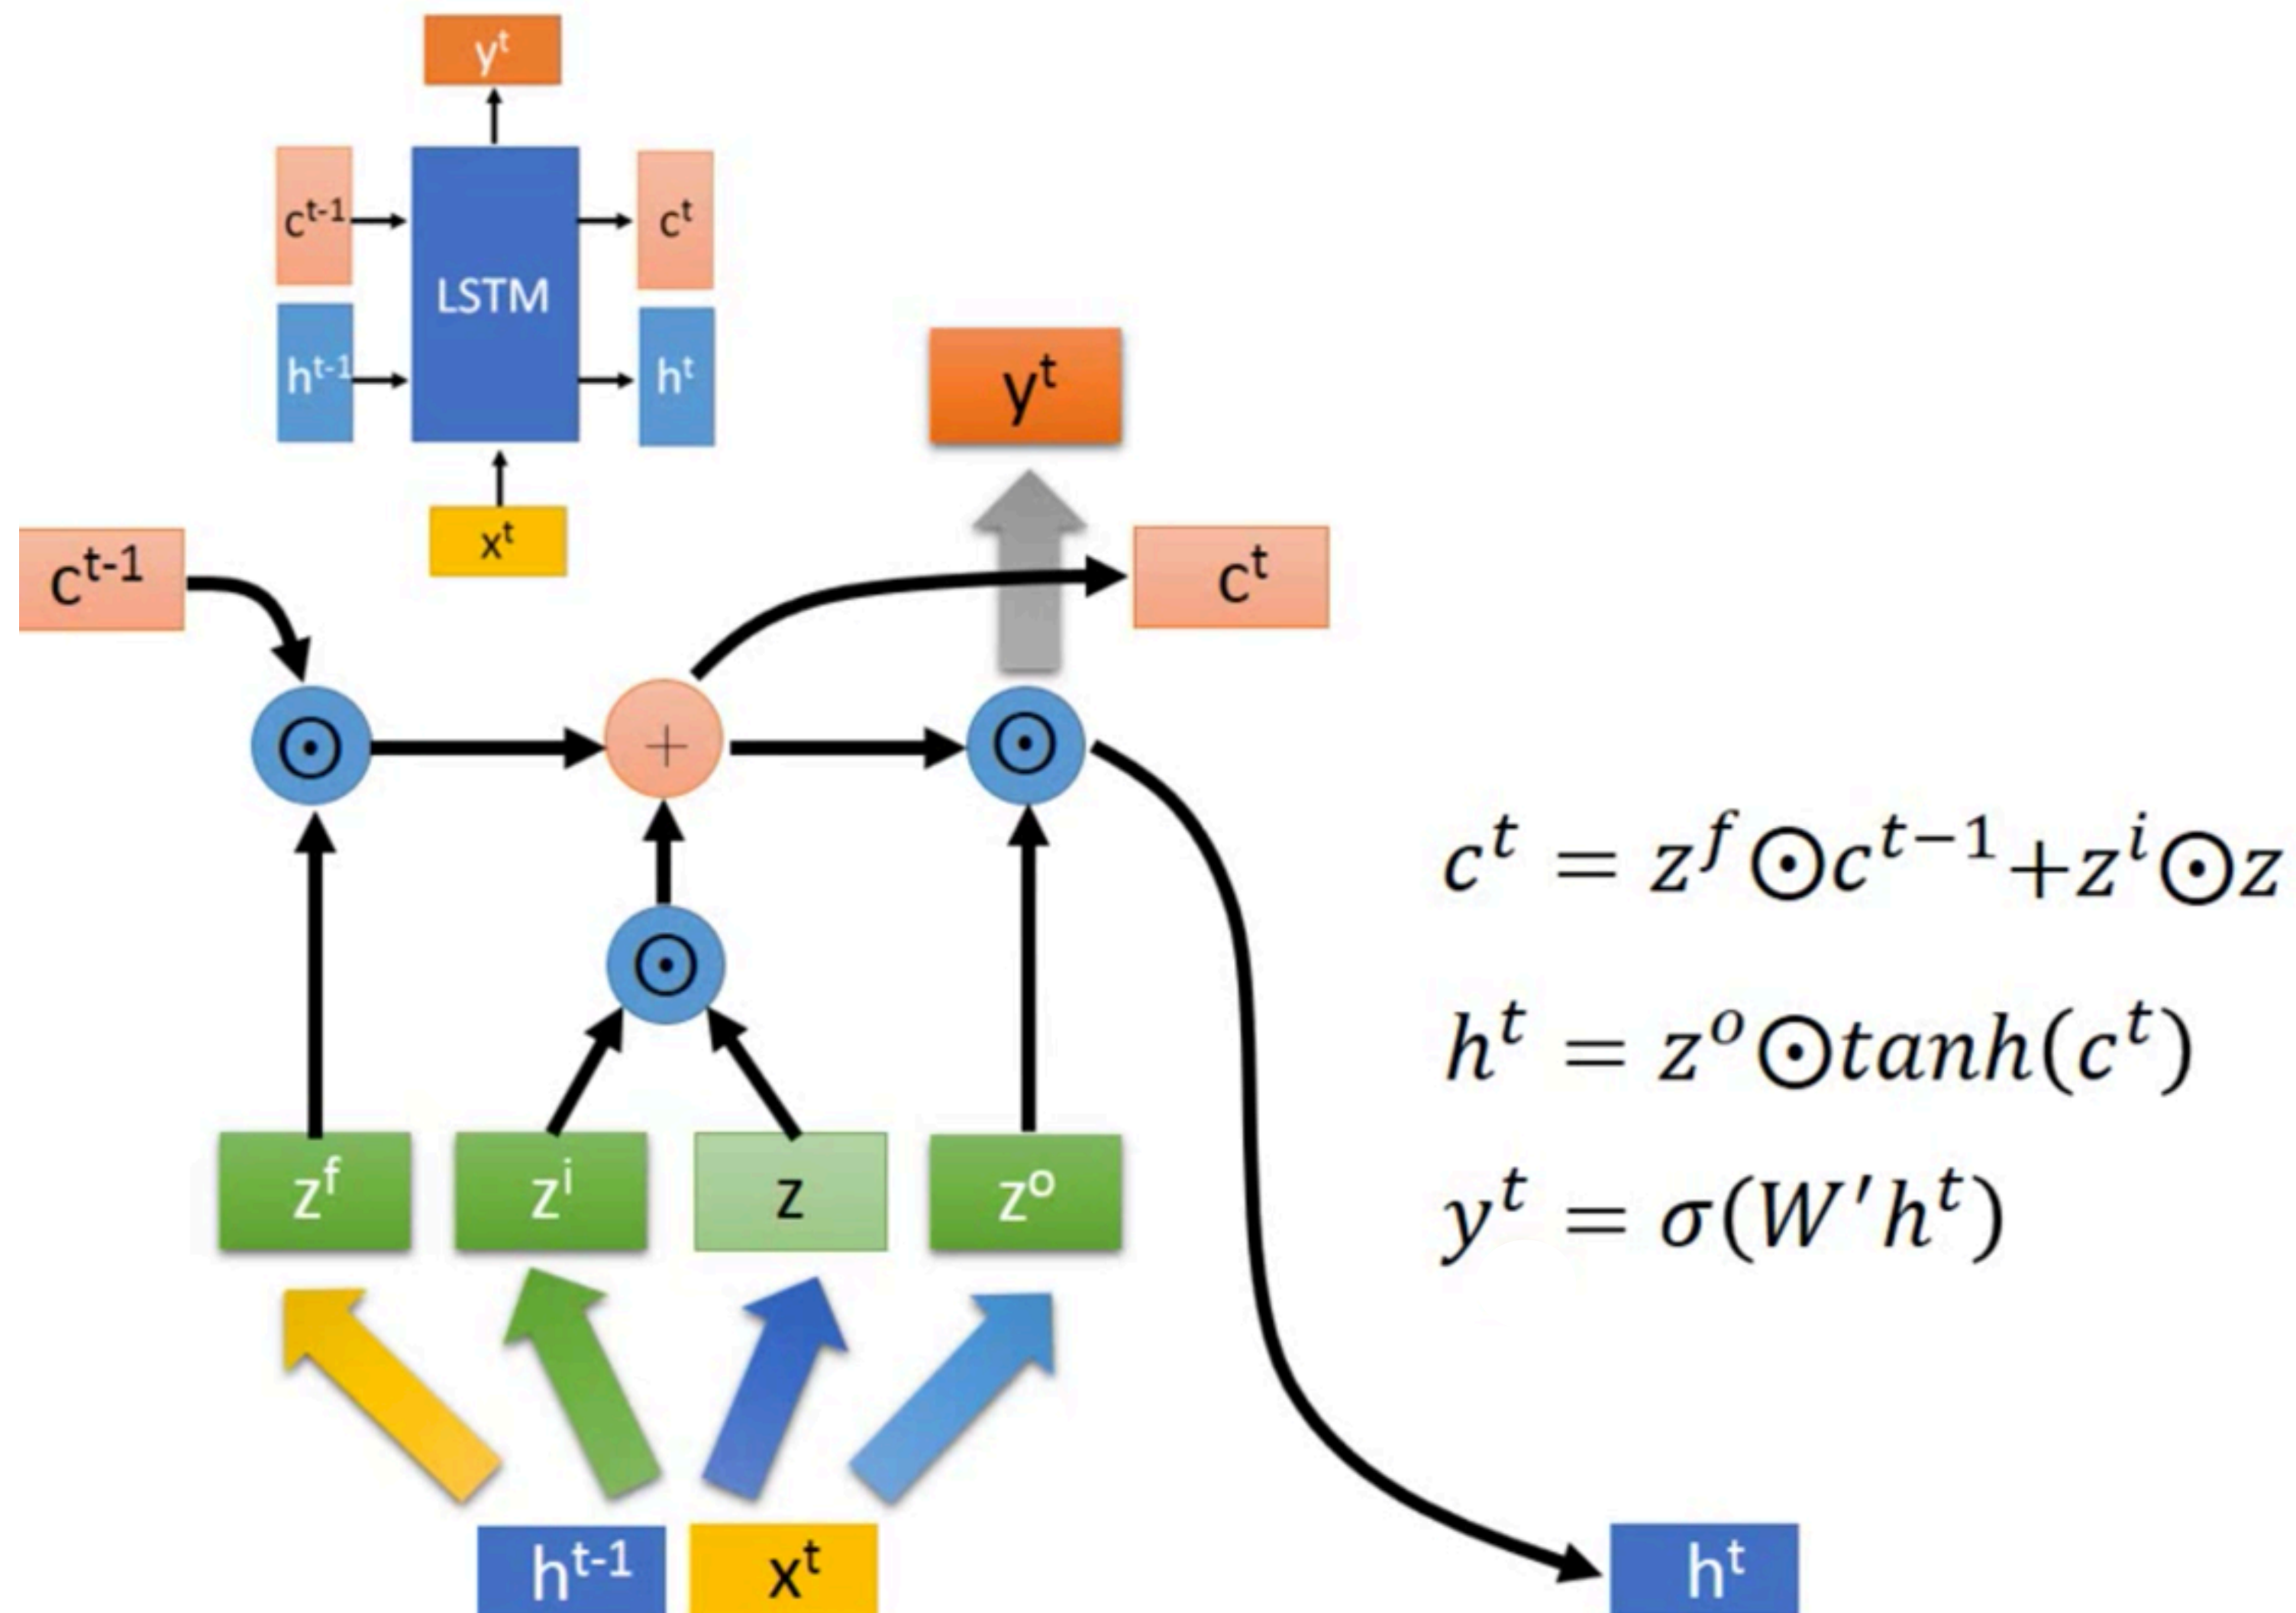
$$z^f = \sigma\left(W^f \begin{bmatrix} x^t \\ h^{t-1} \end{bmatrix}\right)$$

forget gate


$$z^o = \sigma\left(W^o \begin{bmatrix} x^t \\ h^{t-1} \end{bmatrix}\right)$$

output gate

# LSTM



# GRU(Gated Recurrent Unit)

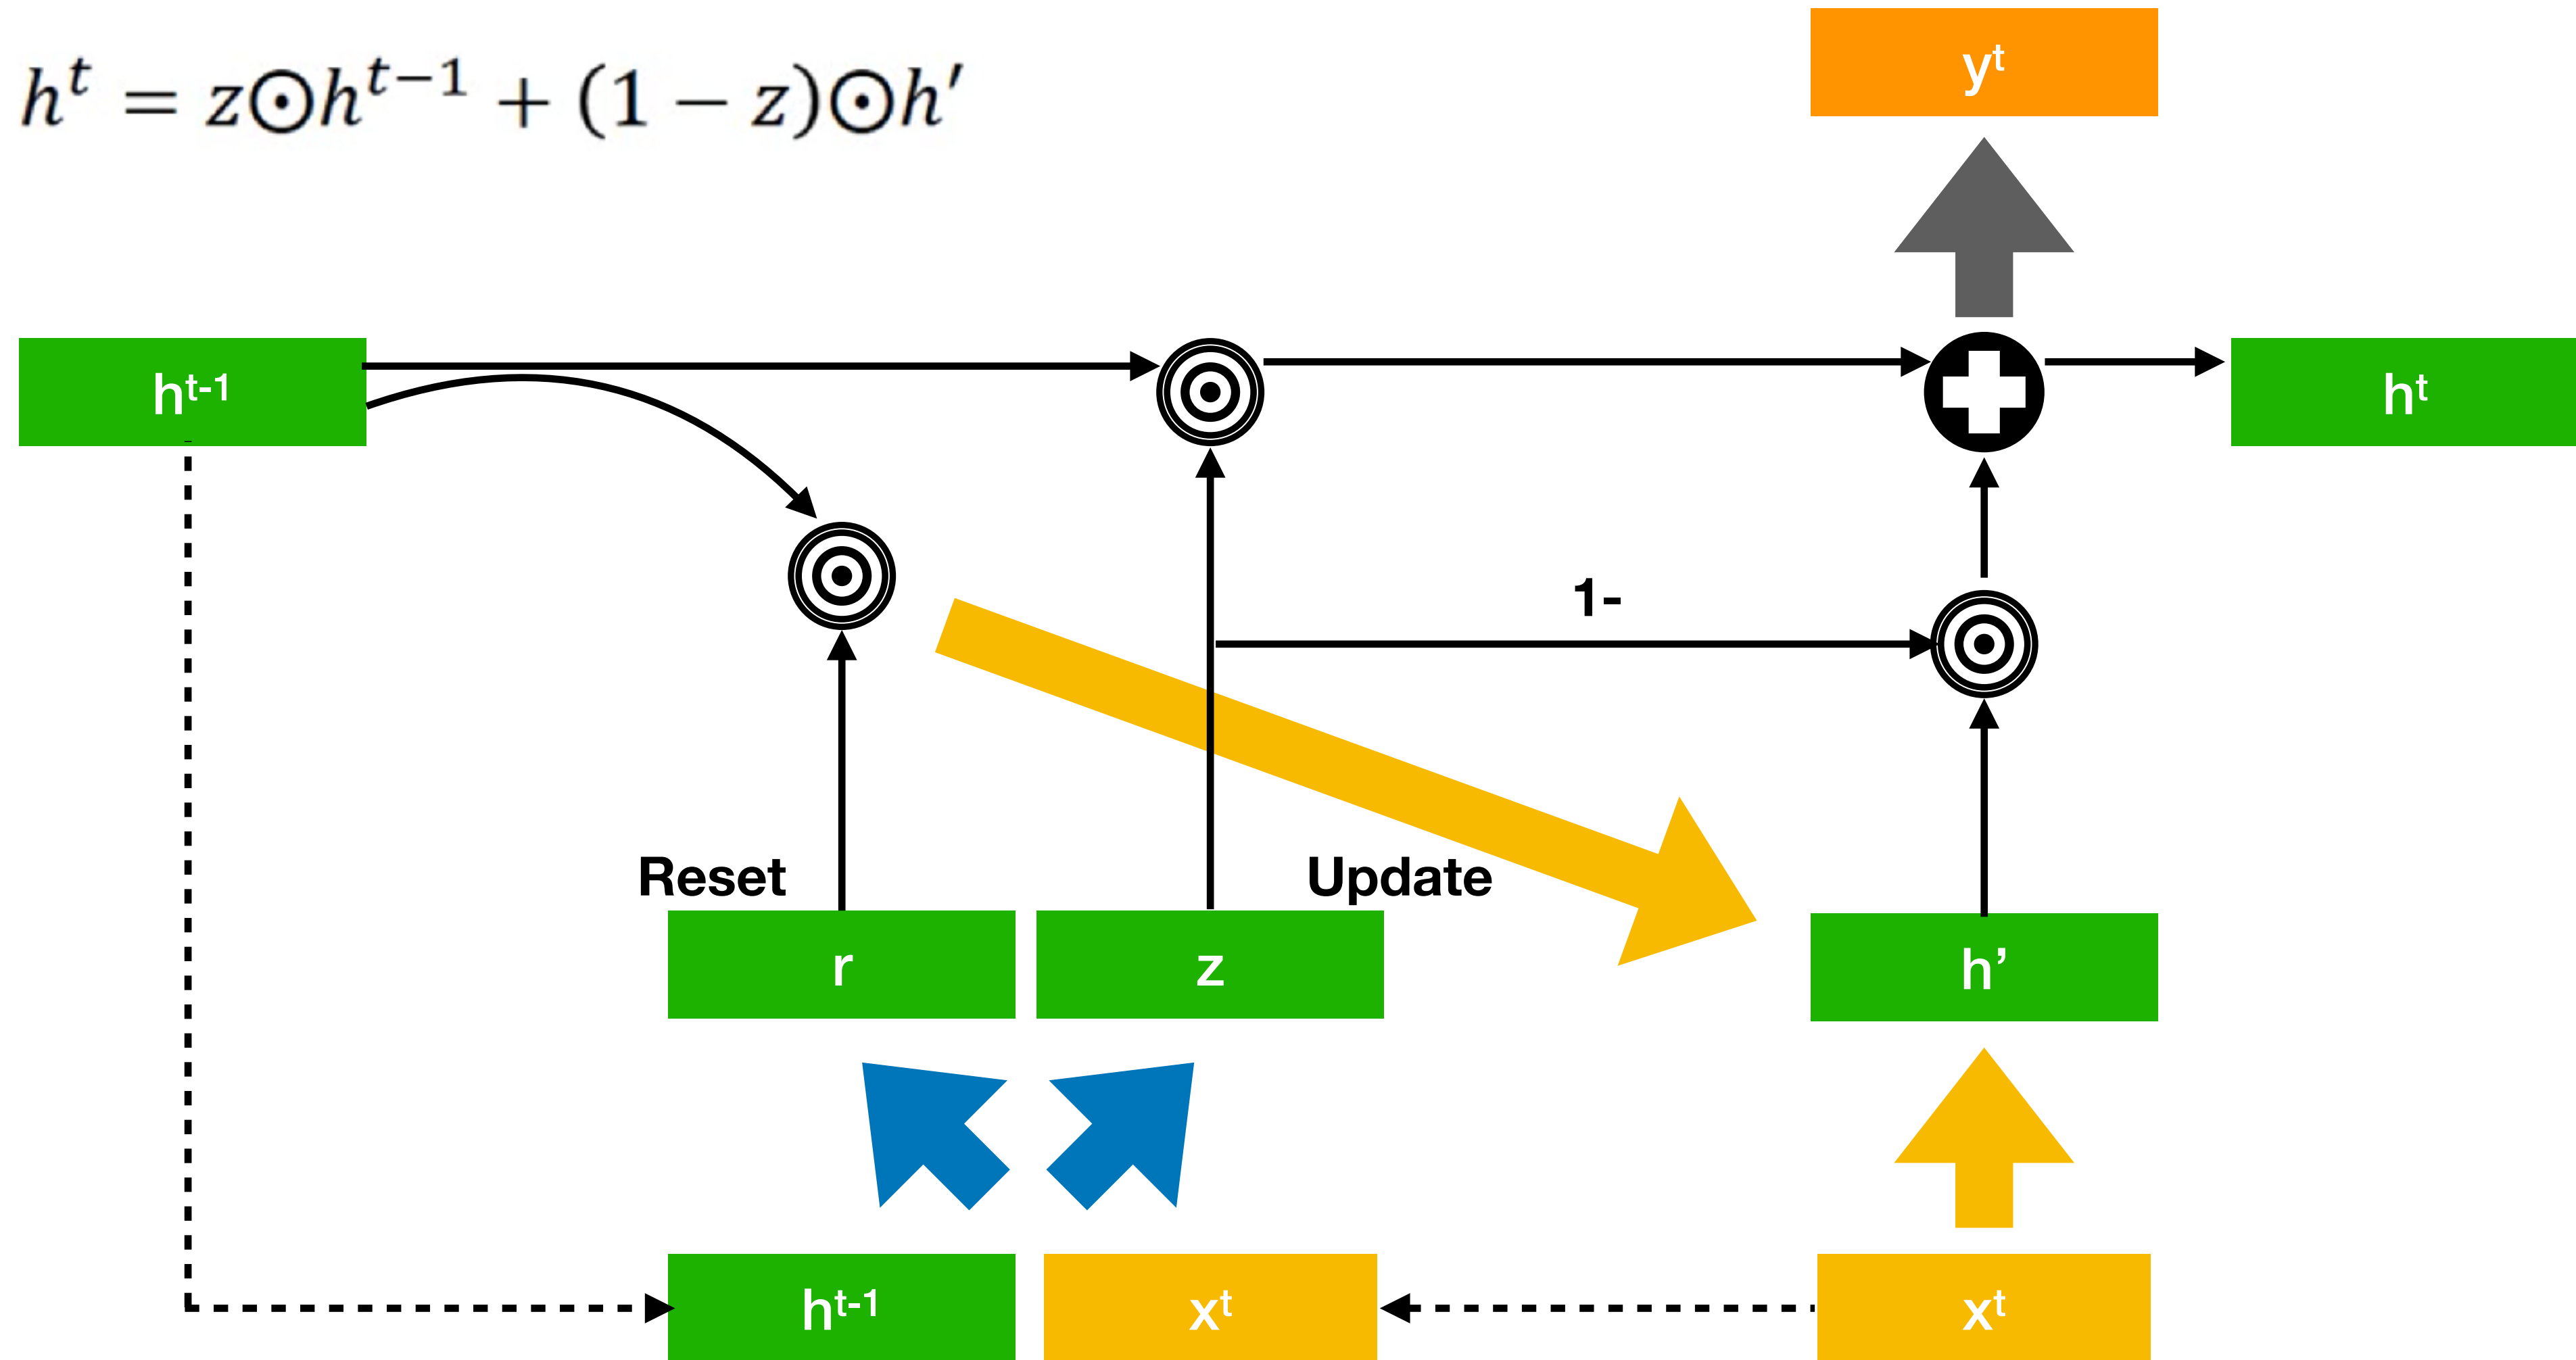


參數較少  
輸入輸出較少  
但performance不一定比較好

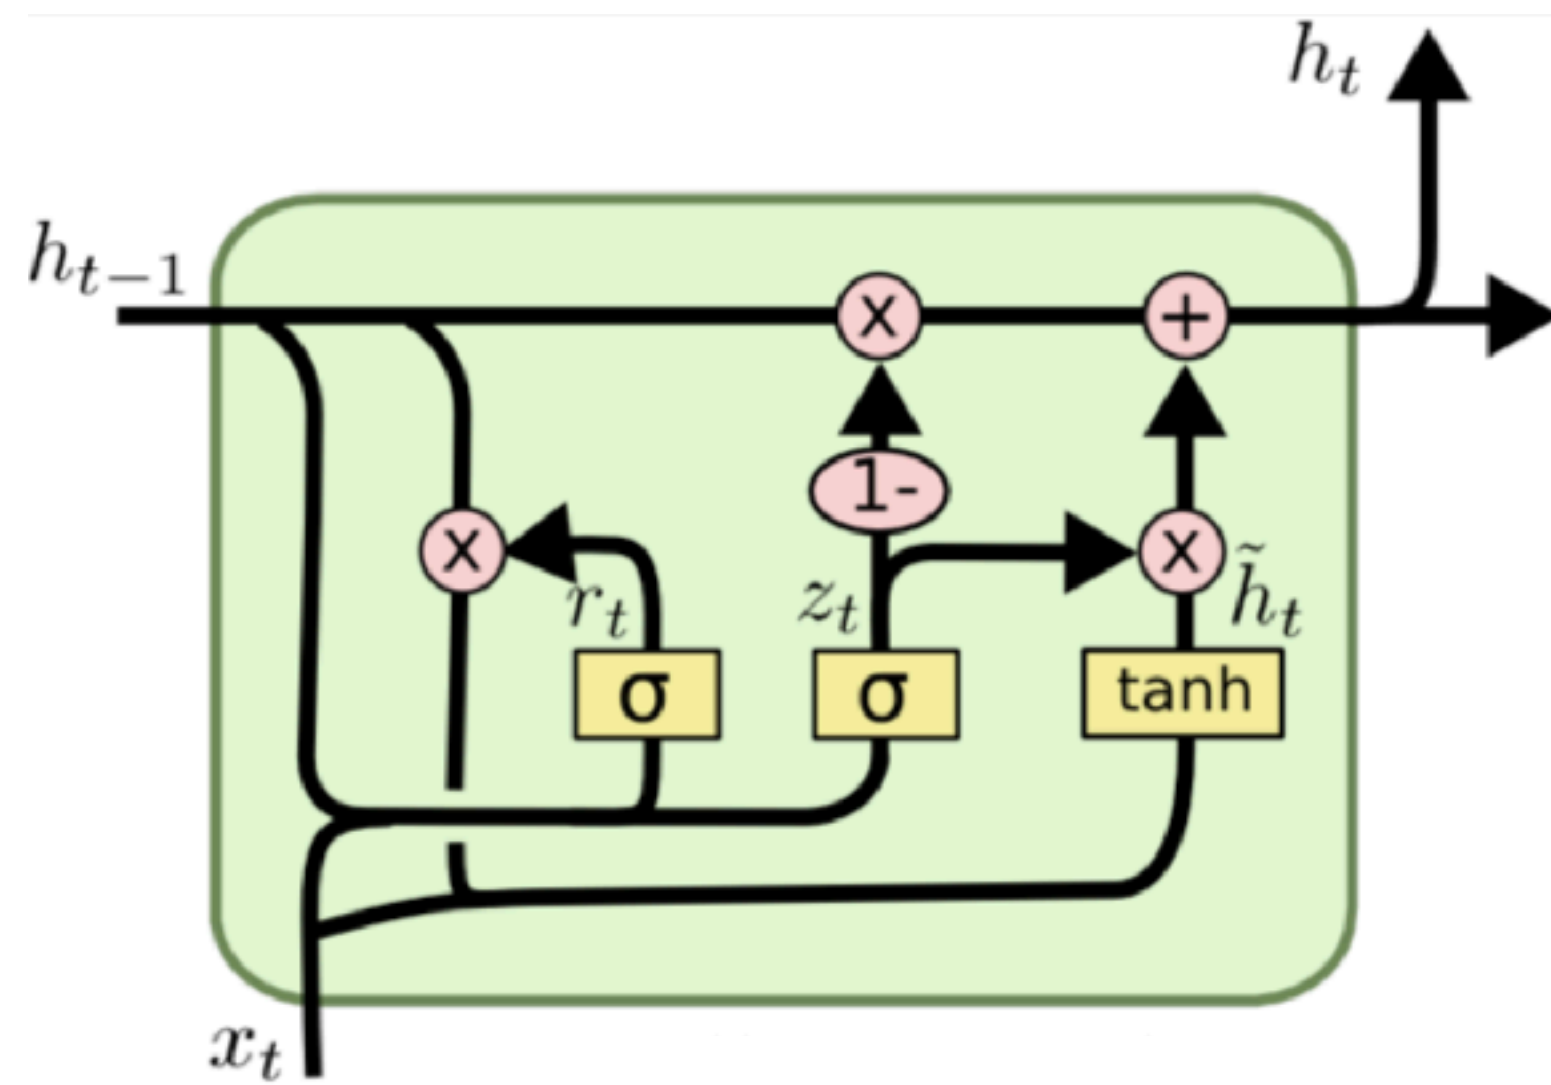


# GRU

$$h^t = z \odot h^{t-1} + (1 - z) \odot h'$$



# GRU



$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

Update Gated

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

Reset Gated

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

Candidate hidden layer

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

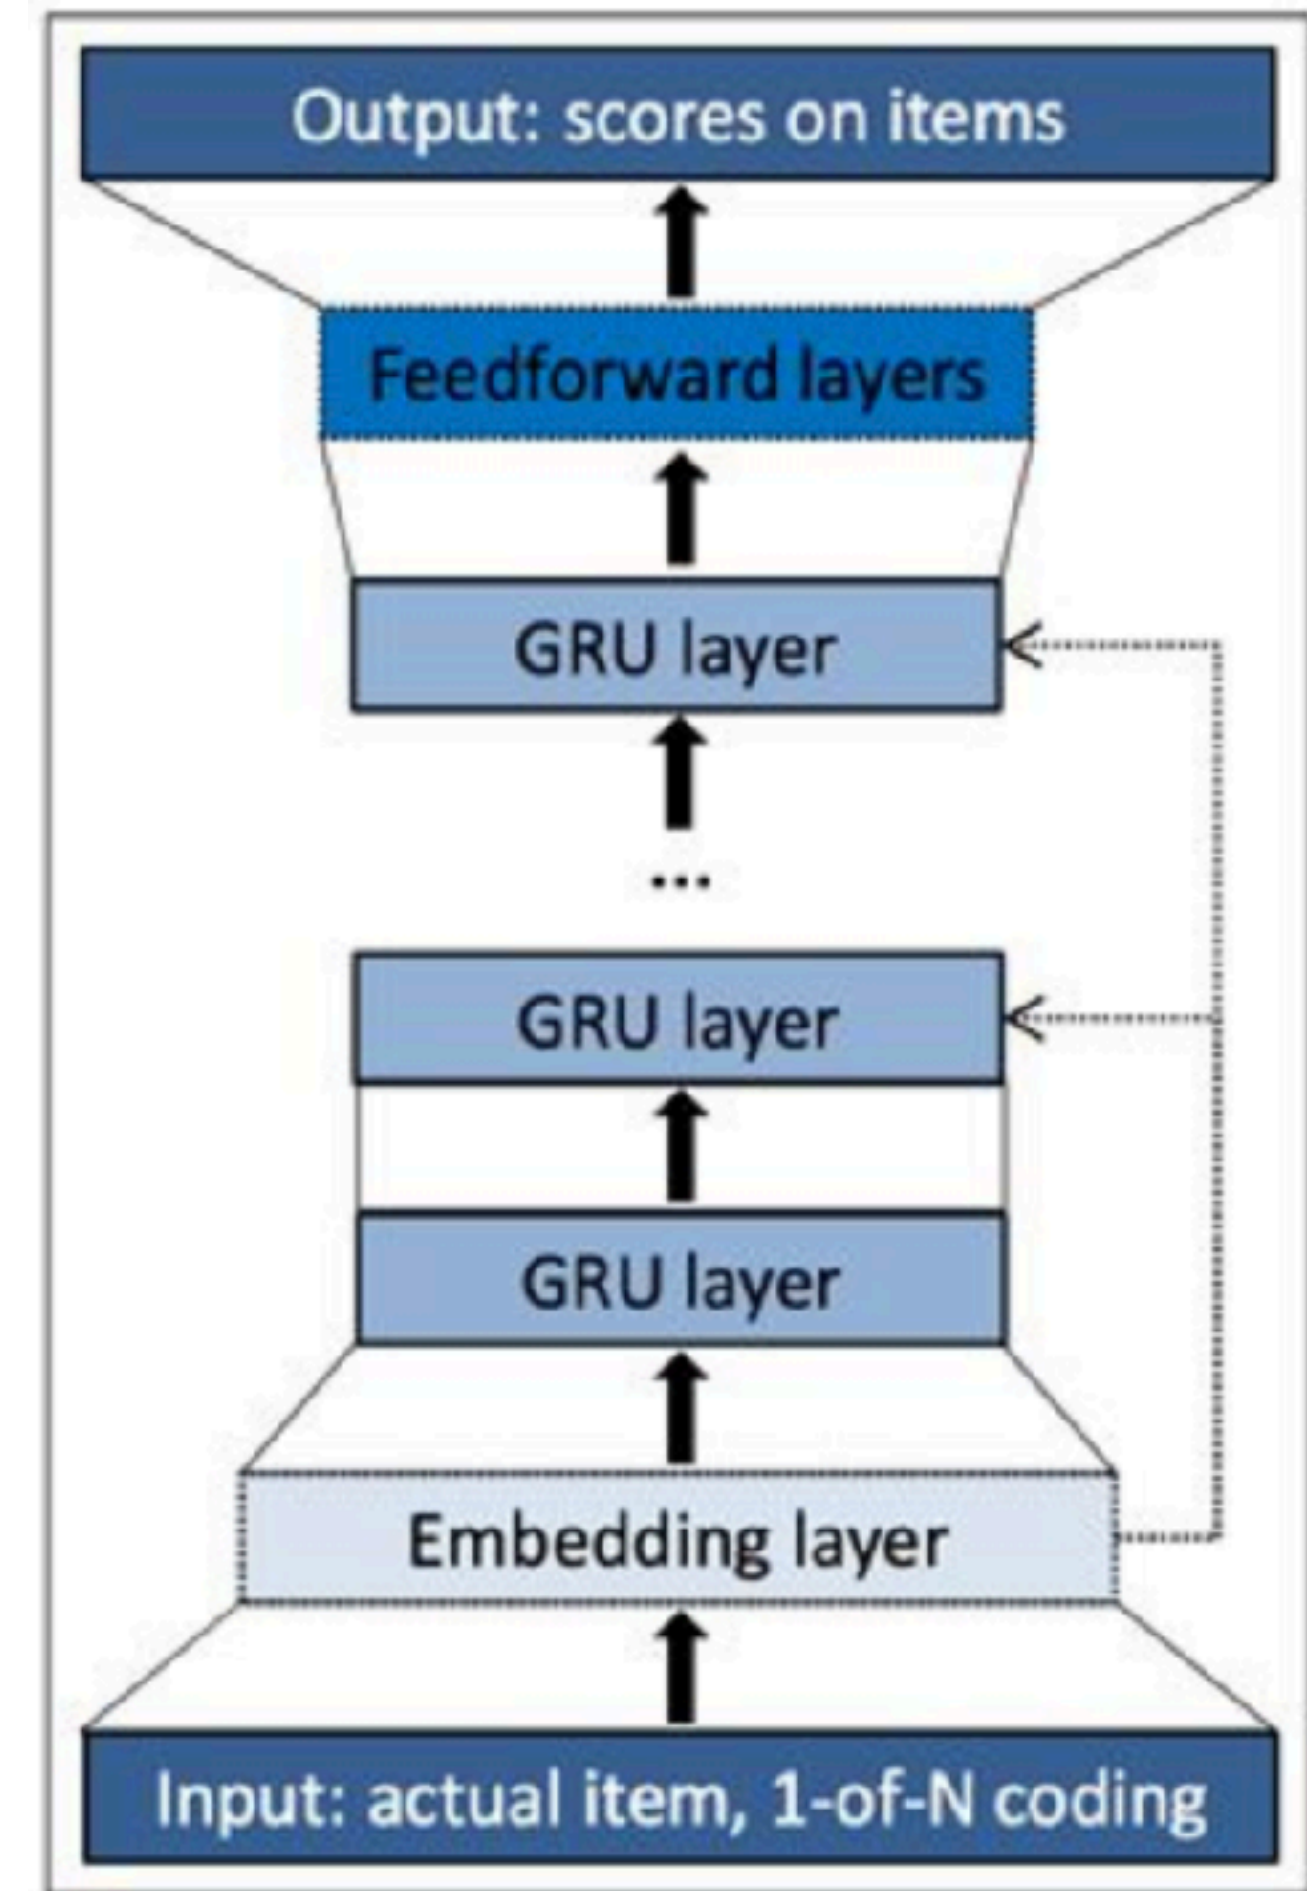
Output Gated

兩個門：更新門、重置門（將LSTM的輸入、遺忘門用更新門代替）



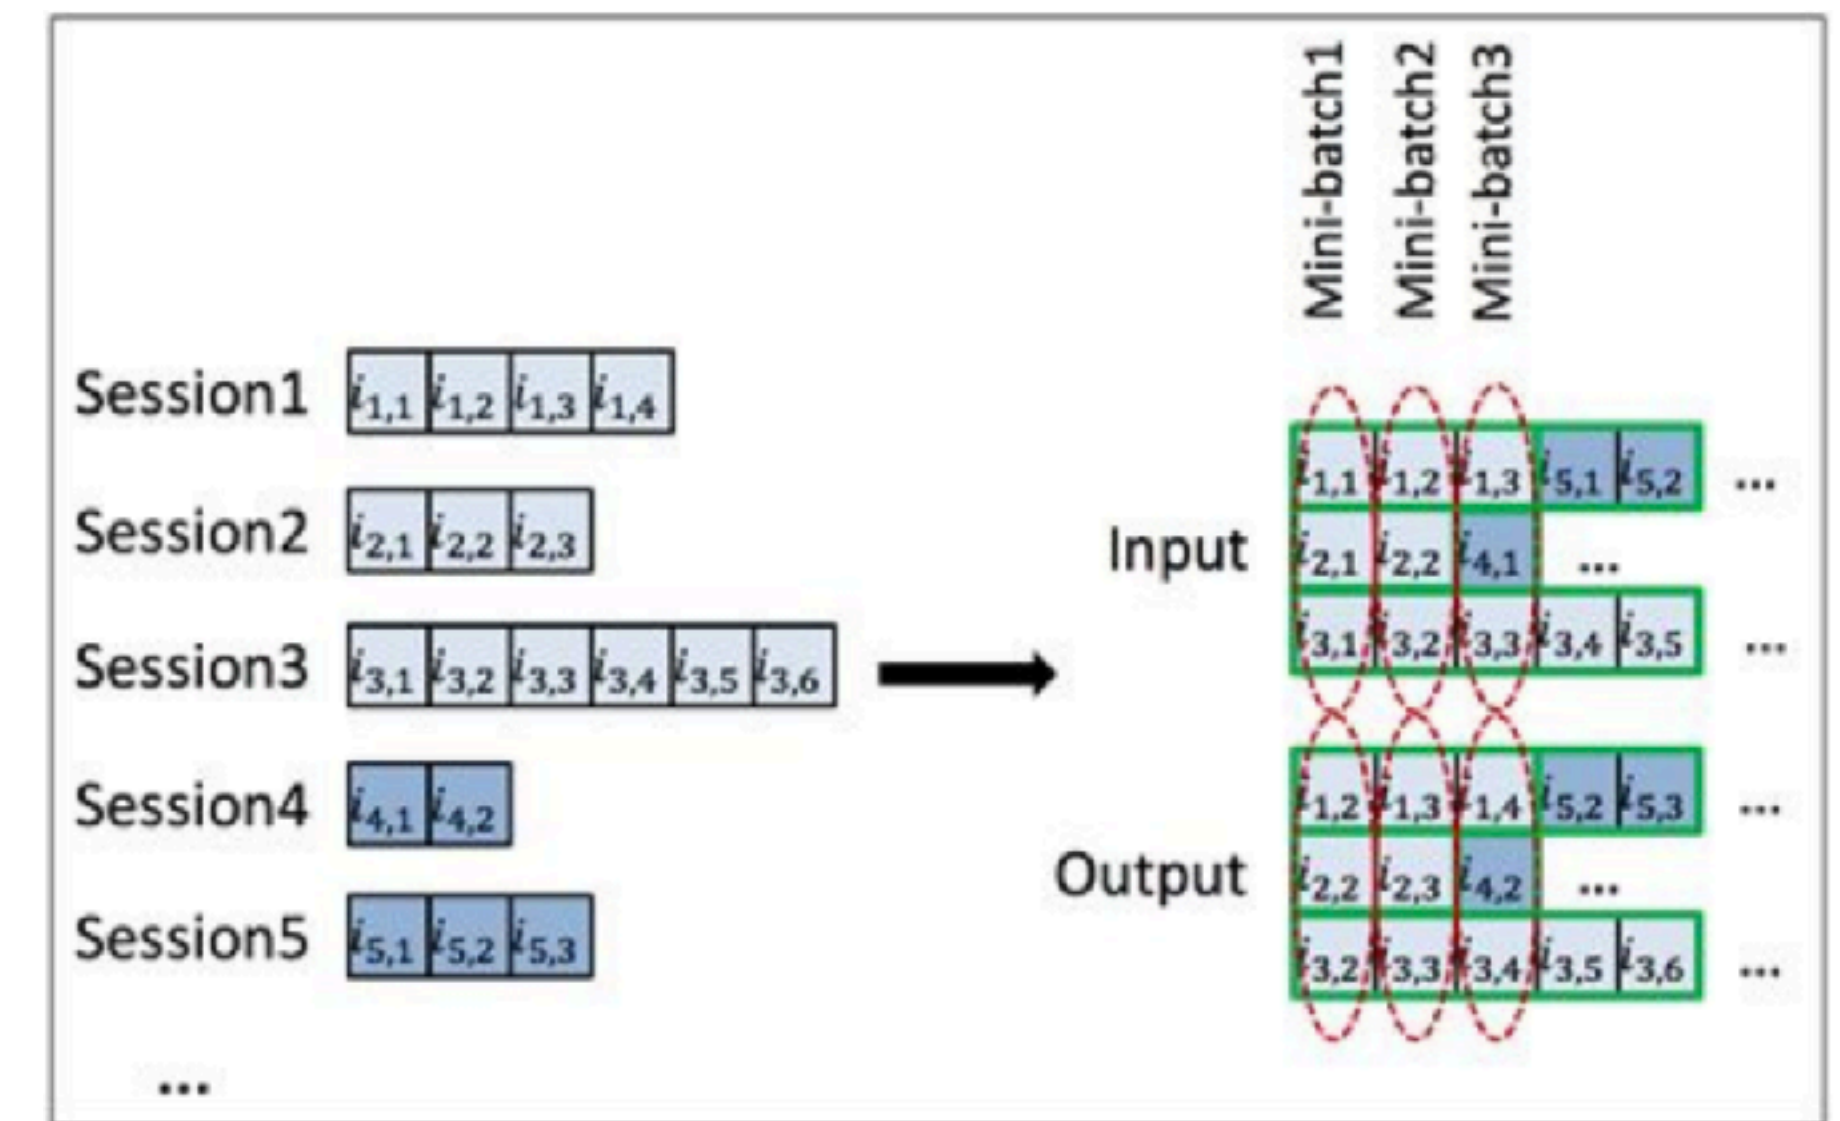
# GRU4REC

- 模型架構
- Input: Session中的點擊序列 $X=[X_1, X_2, \dots, X_{r-1}, X_r]$ 通過One hot encoding，再通過embedding層壓縮為連續低維向量作為GRU輸入
- Output: 每個Item被點擊的預測機率， $y = M(X)$ , where  $y=[y_1, y_2, \dots, y_m]$ 其中M是模型函數、 $y_i$ 是item i的預測點擊機率



# GRU4REC

- 訓練策略（提高訓練效率、簡化訓練代價）
  - Training Strategy: Mini-batch
  - Training data sample: 選取當前正樣本（下一個點擊的item）加上隨機抽取的負樣本（選取同一個mini-batch中其他sequence下一個點擊的item作為負樣本）



# GRU4REC

- **Loss Function**
  - Point-wise ranking loss
  - **Pair-wise ranking loss:**
    - BPR: 基於貝葉斯理論的矩陣分解
    - TOP1: 一種正則估計

# BPR

$$L_s = -\frac{1}{N} * \sum_{j=1}^{N_s} \log(\sigma(\tilde{y}_{s,i} - \tilde{y}_{s,j}))$$

*N<sub>s</sub>: Sample size*

*y<sub>s,k</sub>: item k 在當前session的分數*

*i: session中的下一個item*

*j: 負樣本*

# Bayesian Personalized Ranking(BPR)概念

- 背景：如果商品的數量非常多且用戶非常少，我們關心的是哪些極少數的商品在用戶心中的排序=> 排序問題



u



i



j

$\langle u, i, j \rangle$  表示user對i的優先級高於j，假設有m個用戶、n個用品

訓練成果是兩個分解後的矩陣W和H：

W的維度：m x k

H的維度：n x k

其中k是一個自定義的維度。

對於用戶u，商品i的排序評分為  $\bar{x}_{ui} = w_u \cdot h_i = \sum_{f=1}^k w_{uf} h_{if}$

目標：找到合適的矩陣W, H讓 $\bar{X}$ 和X相似

# Top1

Paper設計的排序損失計算方式，加入類似L2正則化的誤差項

$$L_s = \frac{1}{N_S} \cdot \sum_{j=1}^{N_S} \sigma(\hat{r}_{s,j} - \hat{r}_{s,i}) + \sigma(\hat{r}_{s,j}^2)$$



# 實驗結果

POP: 推薦最受歡迎的item  
S-POP: 推薦當前session最受歡迎的item  
Item-KNN: 推薦與實際item相似的item，  
session向量間的cos similarity

Table 1: Recall@20 and MRR@20 using the baseline methods

Baseline	RSC15		VIDEO	
	Recall@20	MRR@20	Recall@20	MRR@20
POP	0.0050	0.0012	0.0499	0.0117
S-POP	0.2672	0.1775	0.1301	0.0863
Item-KNN	0.5065	0.2048	0.5508	0.3381
BPR-MF	0.2574	0.0618	0.0692	0.0374

Loss / #Units	RSC15		VIDEO	
	Recall@20	MRR@20	Recall@20	MRR@20
TOP1 100	0.5853 (+15.55%)	0.2305 (+12.58%)	0.6141 (+11.50%)	0.3511 (+3.84%)
BPR 100	0.6069 (+19.82%)	0.2407 (+17.54%)	0.5999 (+8.92%)	0.3260 (-3.56%)
Cross-entropy 100	0.6074 (+19.91%)	0.2430 (+18.65%)	0.6372 (+15.69%)	0.3720 (+10.04%)
TOP1 1000	0.6206 (+22.53%)	<b>0.2693 (+31.49%)</b>	<b>0.6624 (+20.27%)</b>	<b>0.3891 (+15.08%)</b>
BPR 1000	<b>0.6322 (+24.82%)</b>	0.2467 (+20.47%)	0.6311 (+14.58%)	0.3136 (-7.23%)
Cross-entropy 1000	0.5777 (+14.06%)	0.2153 (+5.16%)	-	-

# Reference

- Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling
- Session-based recommendations with recurrent neural networks. (ICLR 2016)
- Gated RNN and Sequence Generation (Recorded at Fall, 2017)